Cours de Statistiques descriptives

BOUWE Abalo

November 10, 2025

Plan de la présentation

1. Objectifs de ce cours
2. Introduction à la statistique descriptive
3. Statistique descriptive unidimensionnelle
4. Statistique descriptive bidimensionnelle
5. Prise de décision basée sur les résultats statistiques

Objectifs de ce cours

- Maîtriser les concepts de base (terminologie) de la statistique descriptive.

Objectifs de ce cours

- Maîtriser les concepts de base (terminologie) de la statistique descriptive.
- Maîtriser les notions essentielles sur les distributions statistiques (à un ou deux caractères).

Objectifs de ce cours

- Maîtriser les concepts de base (terminologie) de la statistique descriptive.
- Maîtriser les notions essentielles sur les distributions statistiques (à un ou deux caractères).
- Réaliser une statistique descriptive d'une population ou d'un échantillon.

Objectifs de ce cours

- Maîtriser les concepts de base (terminologie) de la statistique descriptive.
- Maîtriser les notions essentielles sur les distributions statistiques (à un ou deux caractères).
- Réaliser une statistique descriptive d'une population ou d'un échantillon.
- Utiliser des tableaux statistiques à deux dimensions pour résumer l'information contenue dans les distributions jointes.

Objectifs de ce cours

- Maîtriser les concepts de base (terminologie) de la statistique descriptive.
- Maîtriser les notions essentielles sur les distributions statistiques (à un ou deux caractères).
- Réaliser une statistique descriptive d'une population ou d'un échantillon.
- Utiliser des tableaux statistiques à deux dimensions pour résumer l'information contenue dans les distributions jointes.
- Prendre des décisions les plus appropriées sur la base de résultats statistiques.

Organisation du cours

- **Chapitre 1 : Prise en main : Terminologie de base.**

Organisation du cours

- **Chapitre 1 : Prise en main : Terminologie de base.**
- **Chapitre 2 : Statistique descriptive unidimensionnelle.**

Organisation du cours

- **Chapitre 1 : Prise en main : Terminologie de base.**
- **Chapitre 2 : Statistique descriptive unidimensionnelle.**
- **Chapitre 3 : Statistique descriptive bidimensionnelle.**

Organisation du cours

- **Chapitre 1 : Prise en main : Terminologie de base.**
- **Chapitre 2 : Statistique descriptive unidimensionnelle.**
- **Chapitre 3 : Statistique descriptive bidimensionnelle.**
- **Chapitre 4 : Prise de décision basée sur les résultats statistiques.**

Prise en main

La statistique *est une science qui étudie, élabore et applique où besoin est des méthodes de collecte, de traitement et d'analyse qualitative et quantitative des populations et phénomènes concrets pour favoriser la prise de décision.*

NB: La statistique n'a pas pour but la connaissance des éléments des ensembles en ce qui fait leur individualité, mais en ce qu'ils ont en commun en visant l'obtention des résultats globaux.

Le terme STATISTIQUES désigne un ensemble de données caractérisant numériquement un phénomène. Les méthodes d'obtention de ces données ou de ces statistiques relèvent essentiellement des mathématiques et font largement appel à des outils informatique pour leur mise en œuvre.

Quelques domaines d'applications de la statistique

- Economie et finance
  - Econométrie
  - Analyse financière
  - Modèle de prévision économique
- Médecine et Santé
  - Biostatistique
  - Épidémiologie
- Informatique et Technologie
  - Analyse de données volumineuses (Big Data)
  - Apprentissage automatique (Machine Learning)
  - Analyse de données textuelles
- Éducation
  - Évaluation de l'enseignement
  - Analyse des performances scolaires
  - Mesure de l'efficacité des programmes éducatifs

Quelques domaines d'applications de la statistique

- Marketing et Publicité
  - Analyse de marché
  - Segmentation de la clientèle
  - Évaluation de campagnes publicitaires
- Sport
  - Analyse de performance sportive
  - Prédiction de résultats sportifs
  - Analyse de données sportives
- Politique
  - Analyse des données électorales
  - Évaluation de politiques publiques
  - Statistiques criminelles

Statistique descriptive et statistique inférentielle

- **La statistique descriptive :**On regroupe sous ce terme les méthodes statistiques dont l'objectif est la description des données dans leur ensemble. Il faut noter que cette description se fait à partir de :
  * calcul des **résumés numériques** ou **caractéristiques numériques.**
  * leur **représentation graphique**

  NB : Pour la statistique descriptive aucune hypothèse de type probabiliste n'est faite sur les données considérées.
- **La statistique inférentielle :** Ce terme regroupe les méthodes dont l'objectif principal est de préciser un phénomène sur une population globale à partir de son observation sur une partie restreinte de cette dernière. Très souvent ce passage ne peut se faire que moyennant des hypothèses de type probabilistes.

Terminologie de base

- **Population ou collectivité ou univers statistique :** C'est l'ensemble concerné par une étude statistique. On parle aussi de champ de l'étude.

Terminologie de base

- **Population ou collectivité ou univers statistique :** C'est l'ensemble concerné par une étude statistique. On parle aussi de champ de l'étude.
- **Unité statistique :** C'est un élément de la population statistique

Terminologie de base

- **Population ou collectivité ou univers statistique :** C'est l'ensemble concerné par une étude statistique. On parle aussi de champ de l'étude.
- **Unité statistique :** C'est un élément de la population statistique
- **Le caractère statistique :** C'est l'aspect de l'unité statistique retenu pour l'étude

Terminologie de base

- **Population ou collectivité ou univers statistique :** C'est l'ensemble concerné par une étude statistique. On parle aussi de champ de l'étude.
- **Unité statistique :** C'est un élément de la population statistique
- **Le caractère statistique :** C'est l'aspect de l'unité statistique retenu pour l'étude
- **Individu :** On désigne ainsi tout élément de la population considérée.

Terminologie de base

- **Population ou collectivité ou univers statistique :** C'est l'ensemble concerné par une étude statistique. On parle aussi de champ de l'étude.
- **Unité statistique :** C'est un élément de la population statistique
- **Le caractère statistique :** C'est l'aspect de l'unité statistique retenu pour l'étude
- **Individu :** On désigne ainsi tout élément de la population considérée.
- **Échantillon :** On appelle échantillon le sous-ensemble *représentatif* de la population sur lequel sont effectivement réalisées les observations.

Terminologie de base

- **Population ou collectivité ou univers statistique :** C'est l'ensemble concerné par une étude statistique. On parle aussi de champ de l'étude.
- **Unité statistique :** C'est un élément de la population statistique
- **Le caractère statistique :** C'est l'aspect de l'unité statistique retenu pour l'étude
- **Individu :** On désigne ainsi tout élément de la population considérée.
- **Échantillon :** On appelle échantillon le sous-ensemble *représentatif* de la population sur lequel sont effectivement réalisées les observations.
- **Taille de l'échantillon :** C'est le cardinal de l'échantillon. Autrement dit c'est le nombre d'individus qu'il contient. En général on note par n la taille de l'échantillon.

Terminologie de base

- **Enquête :** C'est une opération consistant à observer, à mesurer ou à questionner l'ensemble des individus d'un échantillon.

Terminologie de base

- **Enquête :** C'est une opération consistant à observer, à mesurer ou à questionner l'ensemble des individus d'un échantillon.
- **Recensement :** C'est une enquête dans laquelle l'échantillon observé est en fait la population tout entière.

Terminologie de base

- **Enquête :** C'est une opération consistant à observer, à mesurer ou à questionner l'ensemble des individus d'un échantillon.
- **Recensement :** C'est une enquête dans laquelle l'échantillon observé est en fait la population tout entière.
- **Sondage :** c'est, au contraire, une enquête dans laquelle l'échantillon observé est un sous ensemble strict de la population (on parle, dans ce cas, d'enquête non exhaustive).

Terminologie de base

- **Enquête :** C'est une opération consistant à observer, à mesurer ou à questionner l'ensemble des individus d'un échantillon.
- **Recensement :** C'est une enquête dans laquelle l'échantillon observé est en fait la population tout entière.
- **Sondage :** c'est, au contraire, une enquête dans laquelle l'échantillon observé est un sous ensemble strict de la population (on parle, dans ce cas, d'enquête non exhaustive).
- **Variable :** C'est une caractéristique (âge, taille, état de santé...) définie sur la population et observée sur un échantillon.

Terminologie de base

- **Variable qualitative :** Lorsque la variable ne se prête pas à des valeurs numériques, elle est dite qualitative. A tire d'exemple on a : Les opinions politiques, la couleur des yeux. Les variables qualitatives peuvent être ordonnées ou non ou dichotomique ou non.

Terminologie de base

- **Variable qualitative :** Lorsque la variable ne se prête pas à des valeurs numériques, elle est dite qualitative. A tire d'exemple on a : Les opinions politiques, la couleur des yeux. Les variables qualitatives peuvent être ordonnées ou non ou dichotomique ou non.
- **Variable quantitative :** Lorsque la variable peut être exprimé numériquement, elle est dite quantitative. Dans ce cas, elle peut être *continue* ou *discontinue*.
  - Elle est dite **discontinue** si elle prend que des valeurs isolées les unes des autres. Une variable discontinue qui ne prend que des valeurs entières est dite discrète (exemple : le nombre d'enfants d'une famille ; le nombre de fois ou le Docteur LAMBONI a fait la garde au cours des six derniers mois de l'année 2022).
  - Elle est dite **continue** lorsqu'elle peut prendre toutes les valeurs d'un intervalle fini ou infini.

Terminologie de base

- **Modalité :** Les modalités d'une variable sont les différentes situations possibles dans lesquelles peut se trouver une variable.

Terminologie de base

- **Modalité :** Les modalités d'une variable sont les différentes situations possibles dans lesquelles peut se trouver une variable.
- **Une variable dépendante ou variable à expliquée :** est une variable qui sert à décrire ou à mesurer le problème à l'étude.

Terminologie de base

- **Modalité :** Les modalités d'une variable sont les différentes situations possibles dans lesquelles peut se trouver une variable.
- **Une variable dépendante ou variable à expliquée :** est une variable qui sert à décrire ou à mesurer le problème à l'étude.
- **Une variable indépendante ou variable explicative :**est une variable qui sert à décrire ou à mesurer les facteurs dont on suppose qu'ils sont la cause du problème ou qui, du moins influent sur lui.

Terminologie de base

- **Modalité :** Les modalités d'une variable sont les différentes situations possibles dans lesquelles peut se trouver une variable.
- **Une variable dépendante ou variable à expliquée :** est une variable qui sert à décrire ou à mesurer le problème à l'étude.
- **Une variable indépendante ou variable explicative :**est une variable qui sert à décrire ou à mesurer les facteurs dont on suppose qu'ils sont la cause du problème ou qui, du moins influent sur lui.
- **Une variable confondante ou confusionnelle :** est une variable associée à la fois au problème et une cause possible du problème. Elle peut renforcer ou, au contraire affaiblir le lien apparent entre le problème et une cause possible.

Terminologie de base

- **Une Distribution statistique :** est un tableau de données regroupées par classes ou modalités avec des fréquences ou des effectifs correspondants.

Terminologie de base

- **Une Distribution statistique :** est un tableau de données regroupées par classes ou modalités avec des fréquences ou des effectifs correspondants.
- **Données :** Le terme données est très utilisé en statistique. Il désigne l'ensemble des individus observés (ceux de l'échantillon), l'ensemble des variables considérées et les observations de ces variables sur ces individus. Les données sont en général présentées sous forme de tableaux (individus en lignes et variables en colonnes) et stockées dans un fichier qui peut prendre des formats différents selon le profil des utilisateurs. Voici un tout petit exemple de données (base de données).

Terminologie de base

- **Un questionnaire :** C'est une suite de questions standardisées destinées à normaliser et à faciliter le recueil des témoignages. C'est un outil adapté pour recueillir des informations précises auprès d'un nombre important de participants.

Terminologie de base

Table: Exemple de base de données

ID	Variable 1	Variable 2	Variable 3	Variable 4
1	Valeur 1.1	Valeur 1.2	Valeur 1.3	Valeur 1.4
2	Valeur 2.1	Valeur 2.2	Valeur 2.3	Valeur 2.4
3	Valeur 3.1	Valeur 3.2	Valeur 3.3	Valeur 3.4
4	Valeur 4.1	Valeur 4.2	Valeur 4.3	Valeur 4.4
5	Valeur 5.1	Valeur 5.2	Valeur 5.3	Valeur 5.4
6	Valeur 6.1	Valeur 6.2	Valeur 6.3	Valeur 6.4
7	Valeur 7.1	Valeur 7.2	Valeur 7.3	Valeur 7.4
8	Valeur 8.1	Valeur 8.2	Valeur 8.3	Valeur 8.4
9	Valeur 9.1	Valeur 9.2	Valeur 9.3	Valeur 9.4
10	Valeur 10.1	Valeur 10.2	Valeur 10.3	Valeur 10.4

Introduction

On considérera dans tout ce qui suit une variable statistique qu'on désignera par X. L'objectif étant d'exposer les outils élémentaires adaptés à la nature de X et permettant de présenter cette variable de façon synthétique ; d'en faire une représentation graphique appropriée et d'en résumer les principales caractéristiques. Nous présenterons successivement le cas d'une variable quantitative discrète puis celui d'une variable quantitative continue et nous terminerons par le cas d'une variable qualitative.

Cas d'une variable quantitative discrète

En général on appelle variable quantitative discrète une variable ne prenant que des valeurs discrètes. On peut citer à titre d'exemples le nombre d'enfants dans une famille, le nombre d'étudiants absent aucours d'une journée de cours au CDP, le nombre de fois ou un individu est venu à l'hôpital pour des soins en un mois, le nombre de fois qu'une entreprise à fait ses déclarations de TVA au cours d'une année.

Exemple1: On a ci-dessous l'âge de 56 salariés du CDP.

43	29	57	45	50	29	37	59	46	31	46	24	33	38
49	31	62	60	52	38	38	26	41	52	60	49	52	41
38	26	37	59	57	41	29	33	33	43	46	57	46	33
46	49	57	57	46	43	31	35	36	46	45	55	49	52

La présentation des observations ci-dessus est elle appropriée ?

Présentation des données

Les observations ci-dessus ne sont pas présentées de façon commode. Ainsi la première d'entre elles, 43 figure au total 3 fois dans la liste. L'idée ici est de ne la faire figurer qu'une seule fois en précisant qu'elle y est répliquée 3 fois.
Si en plus de n'être pas répétées ; les différentes observations sont rangées par ordre croissant ; les résultats seront plus commodes à lire. C'est ce que l'on fait lorsqu'on présente les données sous forme de tableau statistique.
On appelle donc *tableau statistique*, un tableau dont la première colonne comporte l'ensemble des τ observations distinctes de la variable X. Ces observations sont rangées par ordre croissant et non répétées. Nous les noterons $\{x_i, i = 1..., \tau\}$. Dans une seconde colonne, on dispose en face de chaque valeur x_i, le nombre de réplications qui lui sont associées. Ces réplications sont appelées effectifs et notées n_i (ainsi $n_i = 3$ lorsque $x_i = 43$.)

Présentation des données

On dit donc qu'à l'observation 43 est associé l'effectif 3.
Autrement dit la valeur 43 a été observé 3 fois.
Les effectifs n_i sont souvent remplacés par les quantités $f_i = \frac{n_i}{n}$ appelées **fréquence**, souvent exprimées en pourcentage.
Notons que n désigne le nombre total d'observations et dans l'exemple 1 ci-dessus

$$n = \sum_{i=1}^{\tau} n_i = 56$$

APPLICATION

Les effectifs et fréquences cumulés

Il peut être utile de compléter le tableau statistique en y rajoutant soit les effectifs cumulés soit les fréquences cumulées.
Ces quantités sont respectivement définies de la façon suivante :

$$N_i = \sum_{j=1}^{i} n_j \quad ; \quad F_i = \sum_{j=1}^{i} f_j$$

N_i, représente le nombre d'observations inférieures ou égales à x_i

APPLICATION

Représentation graphique

Pour une variable discrète, on rencontre essentiellement les graphiques suivant :

- **Le diagramme en bâton :** Il permet de donner une vision d'ensemble des observations réalisées. Ce diagramme comporte donc un axe horizontal (l'abscisse), sur lequel figurent les observations de la variable considérée (ici les âges), et un axe vertical (l'ordonnée), sur lequel figurent les effectifs. On aurait pu, tout aussi bien, y faire figurer les fréquences ou les pourcentages ; cela n'aurait rien changé à l'allure du graphique, puisque les fréquences sont, par définition, proportionnelles aux effectifs. En face de chaque observation figure un trait vertical (un bâton), dont la hauteur est proportionnelle à l'effectif (ou à la fréquence, ou au pourcentage) correspondant.

Représentation graphique

- **Le diagramme cumulatif :** Ce second type de graphique sert à visualiser les effectifs cumulés, ou encore les fréquences ou les pourcentages cumulés. Il permet ainsi de déterminer simplement le nombre, ou la proportion, d'observations inférieures ou égales à une valeur donnée de la série.
- **La boîte à moustache ou boxplot :** Il s'agit d'un graphique très simplement qui résume la série à partir de ses valeurs extrêmes, de ses quartiles et de sa médiane. Le graphique 2.3 donne le diagramme en boîte de l'exemple 1. Dans ce graphique, il n'y a en fait qu'une échelle verticale pour les observations de la variable. La *boîte* est la partie du graphique comprise entre les premiers et troisième quartiles. La médiane, nécessairement située à l'intérieur de la boîte, est représentée par un trait horizontal.

Dans les parties basse et haute du graphique figurent les *moustaches*, joignant le minimum au premier quartile (en bas) et le troisième quartile au maximum (en haut). Ce graphique fournit donc très simplement quelques valeurs caractéristiques de la variable considérée.

On notera qu'il est également possible de réaliser le diagramme en boîte de façon horizontale (on permute les axes horizontaux et verticaux), ce que font certains logiciels.

La notion de quantiles et de ses applications

Définition On a vu que la fréquence cumulée ($0 \leq F_i \leq 1$) donne la proportion d'observations inférieures ou égales à x_i.Une approche complémentaire consiste à se donner, à priori, une valeur $\alpha \in [0, 1]$, et à rechercher x_α telle qu'une proportion α des observations lui sont inférieures ou égales (autrement dit x_α vérifie $F(x_\alpha) \simeq \alpha$). La valeur x_α est appelée *quantile ou fractile d'ordre* α de la série. Les quantiles les plus utilisés sont associés à certaines valeurs particulières de α. Autrement dit, le quantile d'ordre α noté x_α est tel que la proportion des observations qui lui sont inférieures ou égales vaut α, tandis que la proportion des observations qui lui sont supérieures vaut $1 - \alpha$.

La médiane et les quartiles

La médiane est le quantile d'ordre $\frac{1}{2}$. C'est une observaton qui partage la série des observations en deux ensembles d'effectifs

La notion de quantiles et de ses applications

et 50% des observations lui sont inférieures.
Dans le cas de l'exemple précédent, la médiane vaut 45.
Le premier quartile est le quantile d'ordre $\frac{1}{4}$, le troisième quartile est le quantile d'ordre $\frac{3}{4}$. Le second quartile quant à lui est confondu avec la médiane. On voit donc 25% des observations sont inférieures ou égales au premier quartile, tandis que 75% lui sont supérieures. Pour le troisième quartile, les proportions s'inversent : 75% des valeurs lui sont inférieures ou égales, tandis que 25% lui sont supérieures.

Exercice : Pour le cas de l'exemple précédent, déterminier les quantiles d'ordre $\frac{1}{4} et \frac{3}{4}$ et construisez le boîte à moustache correspondante.

Les caractéristiques numériques

Les caractéristiques ou résumés numériques introduites ici servent à synthétiser la série au moyen de quelques valeurs. On distinguera dans ce cas : **les caractéristiques de tendance centrale** et **les caractéristiques de dispersion**.

Caractéristiques de tendance centrale.
Leur objectif est de fournir un ordre de grandeur de la série étudiée. Les deux grandeurs les plus utilisées sont :

- *La moyenne*
- *La médiane*

La moyenne
Tout le monde a déjà calculé et utilisé à diverses reprises une moyenne. La signification de cette dernière est donc à peu près évidente. Mathématiquement, la moyenne est donnée par l'expression suivante :

Caractéristiques de tendance centrale.

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{\tau} n_i x_i = \sum_{i=1}^{\tau} \frac{n_i}{n} x_i = \sum_{i=1}^{\tau} f_i x_i$$

Remarque :

Si l'on doit donner un indicateur de tendance centrale unique pour caractériser le centre d'une série d'observations, on doit choisir entre la moyenne et la médiane. On retiendra que la moyenne est l'indicateur le plus naturel, le plus connu et donc le plus utilisé dans la pratique. De plus la moyenne est définie par une formule mathématique donnant un résultat sans ambiguïté, ce qui n'est pas le cas de la médiane. Par contre, il faut noter que la signification de la moyenne peut être faussée par de trop grandes ou trop petites observations, ce qui n'est pas le cas de la médiane. On préférera la médiane lorsqu'on rencontre la situation évoquée ci-dessus en particulier dans le cas de séries très dissymétriques.

Les caractéristiques de dispersion

Elles servent à préciser la variabilité de la série c'est-à-dire à mesurer l'éloignement de l'ensemble des observations par rapport à leur tendance centrale. On trouve diverses caractéristiques de dispersions certaines étant plus courantes que d'autres. Citons tout d'abord quelques caractéristiques peu utilisées mais qu'il est néanmoins bon de connaître.

- *l'étendue :* $x_\tau - x_1$ C'est l'écart entre la plus grande et la plus petite des observations. Cette caractéristique est totalement liée à celle de deux valeurs extrêmes donc peu "fiable". Néanmoins elle donne une première idée de la dispersion des observations.
- *L'intervalle inter-quartiles :* $x_{\frac{3}{4}} - x_{\frac{1}{4}}$ C'est l'écart entre le troisième et le premier quartile. Il correspond donc à la longueur de la boîte à moustache. Cette caractéristique est assez intéressante car elle est complètement indépendante des

Les caractéristiques de dispersion

En pratique, la caractéristique la plus utilisée est **l'écart type** qui correspond à la racine carrée de la **variance**. Mathématiquement la variance de la variable X est donnée par la formule suivante :

$$Var(X) = s_x^2 = \frac{1}{n}\sum_{i=1}^{\tau} n_i (x_i - \overline{x})^2 \quad (1)$$

$$= \frac{1}{n}\sum_{i=1}^{\tau} n_i x_i^2 - \overline{x}^2 \quad (2)$$

Remarque : La variance est toujours positive.

Exercice :
1) Montrer que (1) = (2)
2) Déterminer les caractéristiques de tendances centrale et de dispersion du jeu de données de l'exemple 1

Cas d'une variable quantitative continue

Comme dans le cas discret, le tableau statistique permet de présenter de manière synthétique les observations d'une variable quantitative continue. Par contre, les graphiques changent dans ce cas : la répartition des observations est représentée au moyen d'un histogramme, tandis que leur cumul est maintenant représenté au moyen de la courbe cumulative. Enfin, les caractéristiques numériques qui résument ces variables sont les mêmes que dans le cas discret, mais leur calcul nécessite quelques adaptations.

Généralités

Une variable quantitative est dite **continue** lorsque les observations qui lui sont associées ne sont pas des valeurs précises, mais des intervalles. Cela signifie que, dans ce cas, l'ensemble des valeurs possibles de la variable étudiée a été divisé en r intervalles contigus appelés classes.

Cas d'une variable quantitative continue

En général, les deux raisons qui peuvent amener à considérer comme continue une variable quantitative sont le grand nombres d'observations distinctes et le caractère sensible de la variable.

Exercices

Exercice 1

Dans un district sanitaire, lors d'une étude expérimentale consistant à évaluer l'effet curatif d'un nouveau médicament on a pesé les patients présents venus en consultation.

Pois en(Kg)	[28; 37[	[37; 46[	[46; 55[	[55; 64[	[64; 73[	[73; 82[	[82; 91[
Effectif	3	51	74	112	92	62	6

Sont demandés : *histogramme des effectifs, effectifs cumulés, fonction de distribution des effectifs, classe modale, moyenne, étendue, variance et l'écart-type.*

Cas d'une variable quantitative continue

Exercice 2

Dans un échantillon d'étudiants de sexe masculin, on a mesuré la masse de chacun. Les masses ont été arrondies à l'entier. Les données ont été groupées en 7 classes :

Masse en(Kg)	$[45;54[$	$[54;63[$	$[63;72[$	$[72;81[$	$[81;90[$	$[90;99[$	$[99;108[$
Effectif	14	33	33	47	26	13	2

Sont demandés : fréquences, histogramme des fréquences, fréquences cumulées, fonction de distribution des fréquences, classe modale, moyenne, médiane, étendue, variance, écart-type, premier quartile, troisième quartile et l'écart-interquartile.

Cas d'une variable qualitative

C'est encore le tableau statistique qui permet de présenter les données dans ce cas, même si les quantités cumulés n'ont souvent plus de signification. Les graphiques relatifs aux variables qualitatives sont assez particulier à cause de la nature de ces variables. Toujours pour la même raison il n'existe pas de résumé numérique pour une variable qualitative.

Variables nominales et variables ordinales

Par définition, les observations d'une variable qualitative ne sont pas des valeurs numériques mais des caractéristiques appelées modalités. Lorsque ces modalités sont naturellement ordonnées (par exemple la mention au bac dans une population d'étudiants), la variable est dite **ordinale**. Dans le cas contraire (par exemple, la profession dans une population de personnes actives) la variable est dite **nominale**.

Cas d'une variable qualitative

Traitements statistiques

Il est clair qu'on ne peut pas envisager de calculer des caractéristiques numériques avec une variable qualitative (qu'elle soit nominale ou ordinale). Dans l'étude statistique d'une telle variable, on se contentera donc de faire des tableaux statistiques et des représentations graphiques. Encore faut-il noter que les notions d'effectifs cumulés et de fréquences cumulées n'ont de sens que pour des variables ordinales (elles ne sont pas définies pour des variables nominales).

Exemple2

Le tableau ci-dessous donne la répartition de la population active occupée selon la catégorie socio-professionnelle au Gondwana, en mars 1988.

Cas d'une variable qualitative

CSP	effectif	fréqunces(%)
agriculteurs exploitants	1312	6,099772188
artisants,commerçants, chef d'entr	1739	8,08498768
cadres, professions intellectuelles s	2267	10,53977405
professions intermédaires	4327	20,11716026
employés	5815	27,03519457
ouvriers	6049	28,12311126
Total	**21509**	**100**

Représentations graphiques

Les représentations graphiques que l'on rencontre avec les variables qualitatives sont assez nombreuses. Les trois plus courantes qui sont aussi les plus appropriées, sont :

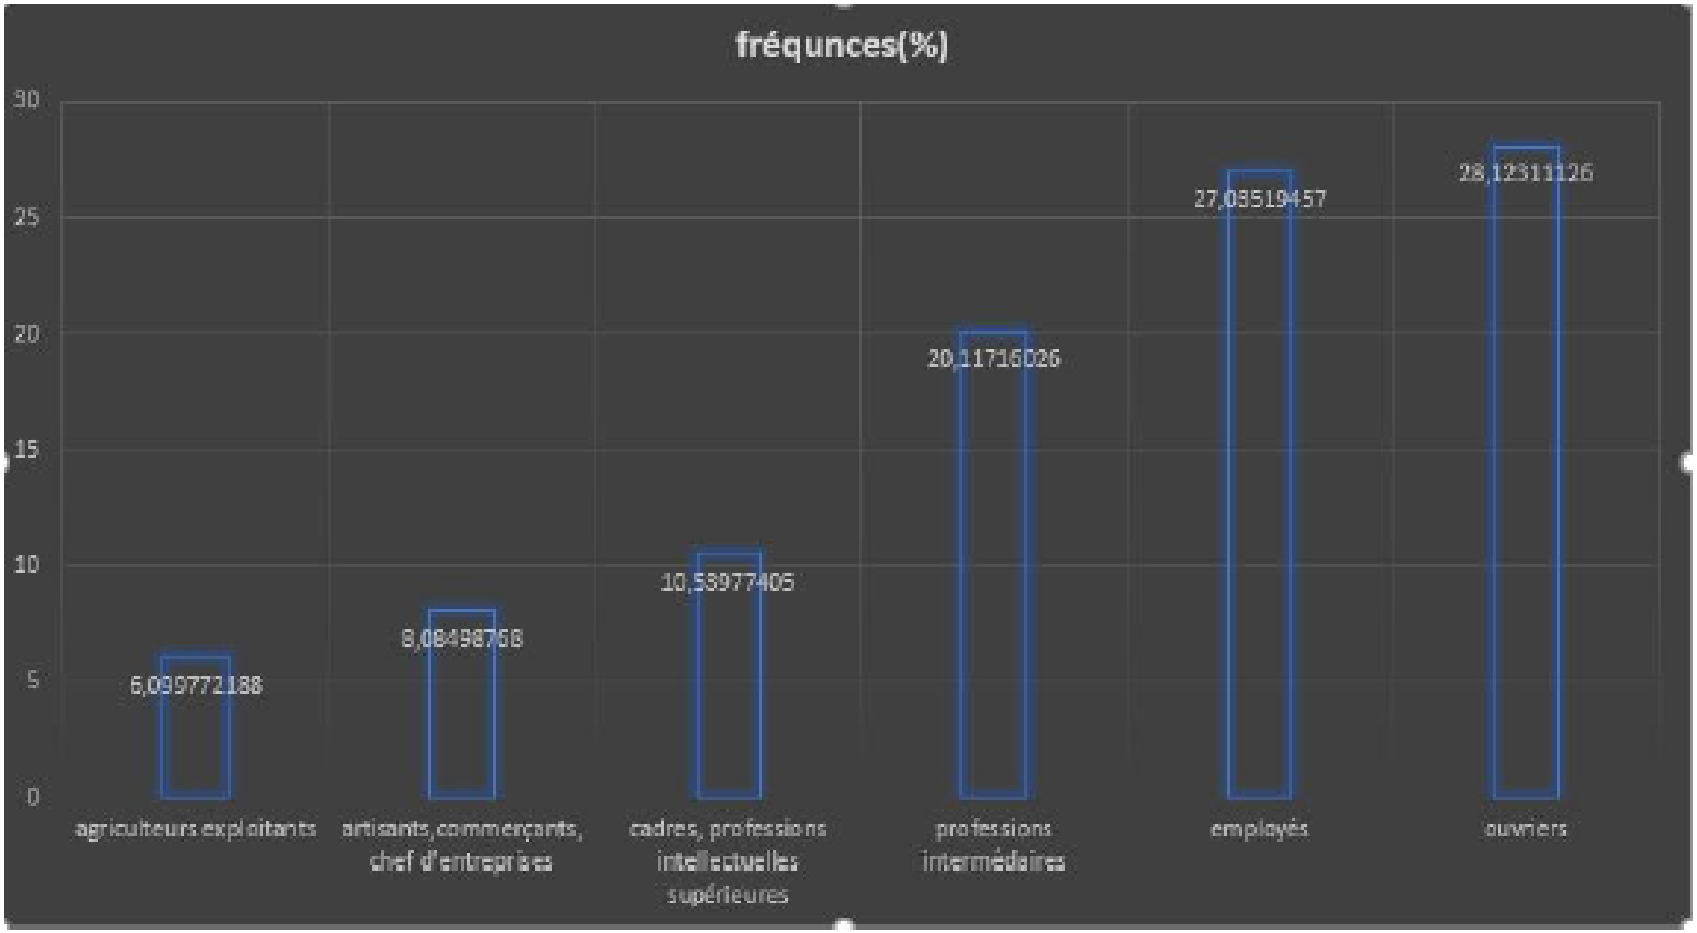
Cas d'une variable qualitative

- *Le diagramme en colonnes ;*
- *Le diagramme en barre ;*
- *Le diagramme en secteurs.*

Le principe général de ces trois graphiques est le même. Les différentes modalités de la variable qualitative sont représentées par des parties du graphique dont la surface est professionnelle à l'effectif (ou la fréquence ou le pourcentage) correspondant. Cette proportionnalité est très évidente dans le diagramme en colonne par contre elle l'est moins dans les deux autres diagrammes.

Cas d'une variable qualitative

Représentations graphiques



Cas d'une variable qualitative

Représentations graphiques

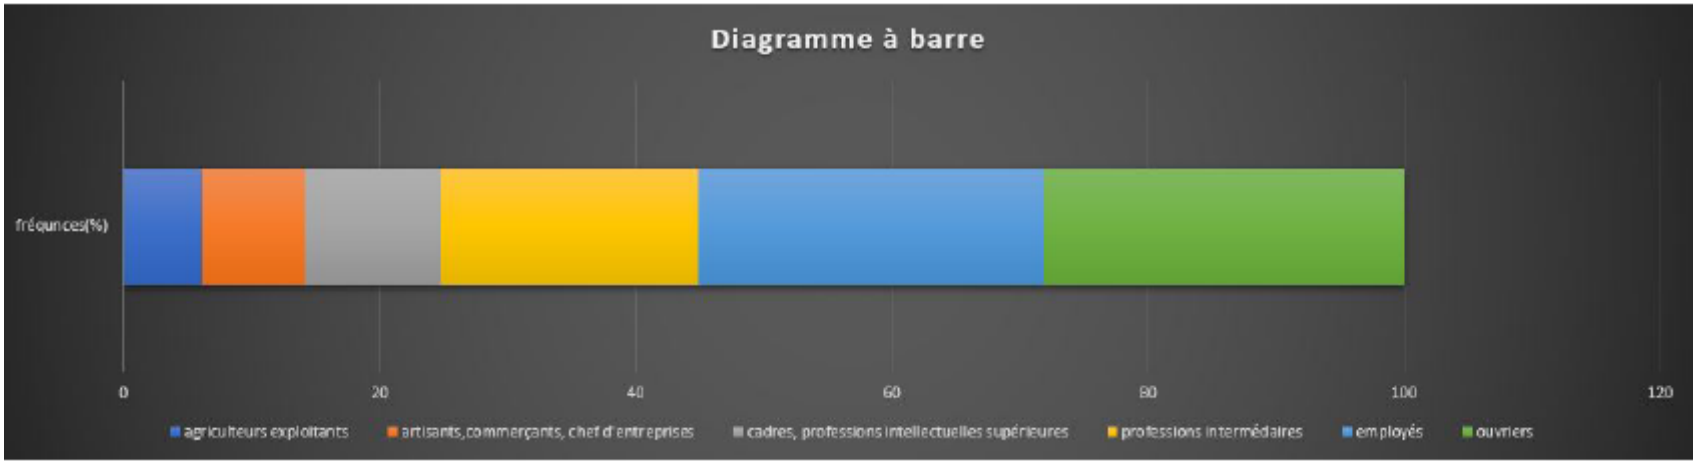


Figure: Diagramme en colonne en barre

Cas d'une variable qualitative

Représentations graphiques

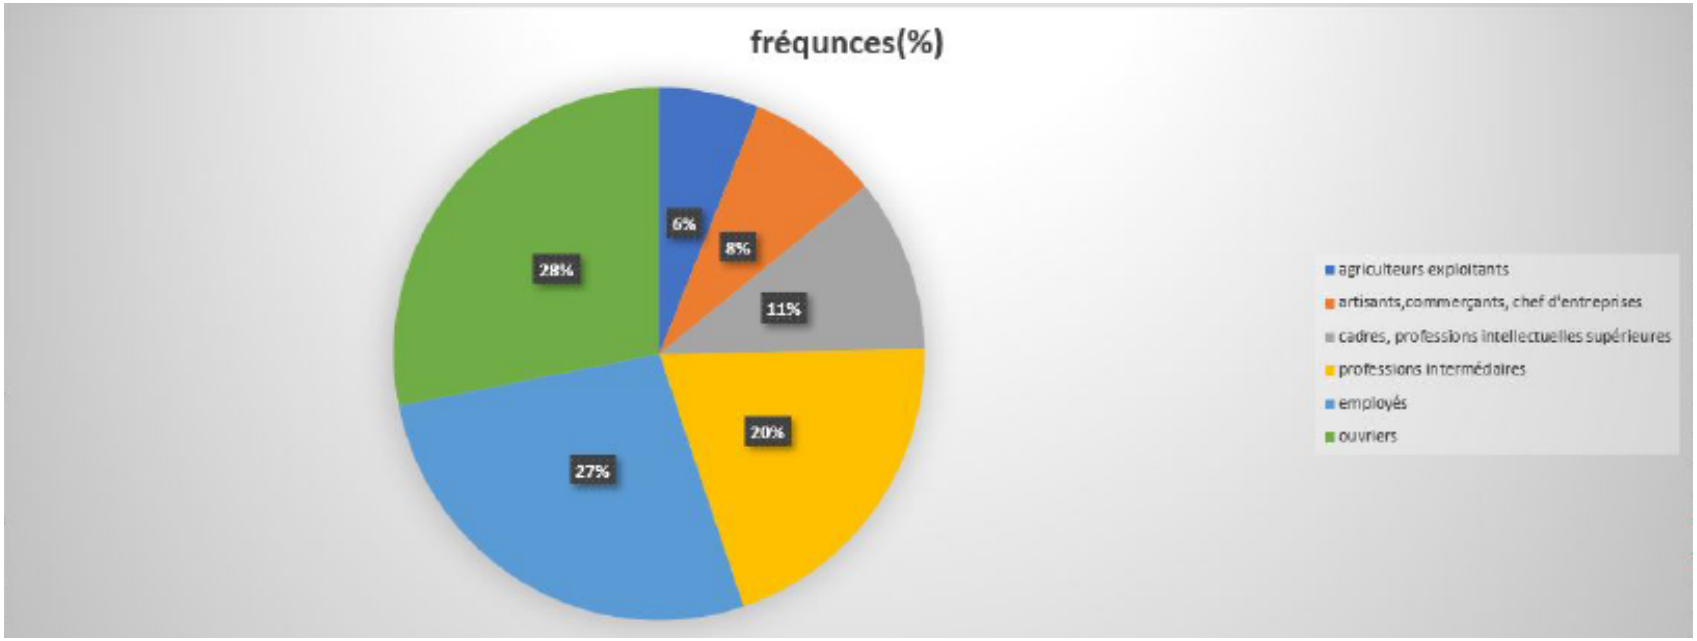


Figure: Diagramme en secteurs ou diagramme circulaire

Introduction

Dans le chapitre précédent, nous avons présenté les méthodes qui permettent de résumer les informations relatives à une variable. Un même individu peut être étudié à l'aide de plusieurs caractères ou variables. A titre d'exemple, les salariés en regardant leur ancienneté et leur niveau d'étude, la croissance d'un enfant en regardant son poids et sa taille, le niveau d'un étudiant du collège de paris en analyse de données ses notes en statistique descriptive et en algèbre linéaire.

Dans ce chapitre, on s'intéresse à l'étude simultanée de deux variables X et Y, étudiées sur un même échantillon. L'objectif essentiel des méthodes qui seront présentées est de mettre en évidence une éventuelle liaison entre les deux variables.

Introduction

Dans certains cas, cette liaison peut être considérée a priori comme causale, une variable X expliquant l'autre Y ; dans d'autres, ce n'est pas le cas, et les deux variables jouent des rôles symétriques. Ainsi nous introduirons les notions de covariance, coefficient de corrélation linéaire, régression linéaire, rapport de corrélation, indice de concentration, khi-deux et autres indicateurs qui lui sont liés. De même, nous présenterons les graphiques illustrant les liaisons entre variables : nuage de points, diagrammes-boîtes parallèles, diagramme de profils, tableau de nuages.

Cas de deux variables quantitatives

- **Nuage de points**

Il s'agit d'un graphique très utilisé pour représenter les observations simultanées de deux variables quantitatives. Il consiste en effet à considérer deux axes perpendiculaires dont l'axe horizontal représente la variable X et l'axe vertical la variable Y, puis à représenter chaque individu observé par les coordonnées des valeurs observées. L'ensemble de ces points est appelé **nuage.** Notons qu'on rencontre parfois la terminologie de **diagramme de dispersion** qui est une traduction de **scatter-plot**

Remarque :
Le choix des échelles à retenir pour réaliser un nuage de points est très délicat. D'une façon générale, on distinguera le cas de variables homogènes (représentant la même grandeur et exprimées dans la même unité) de celui des variables hétérogènes.

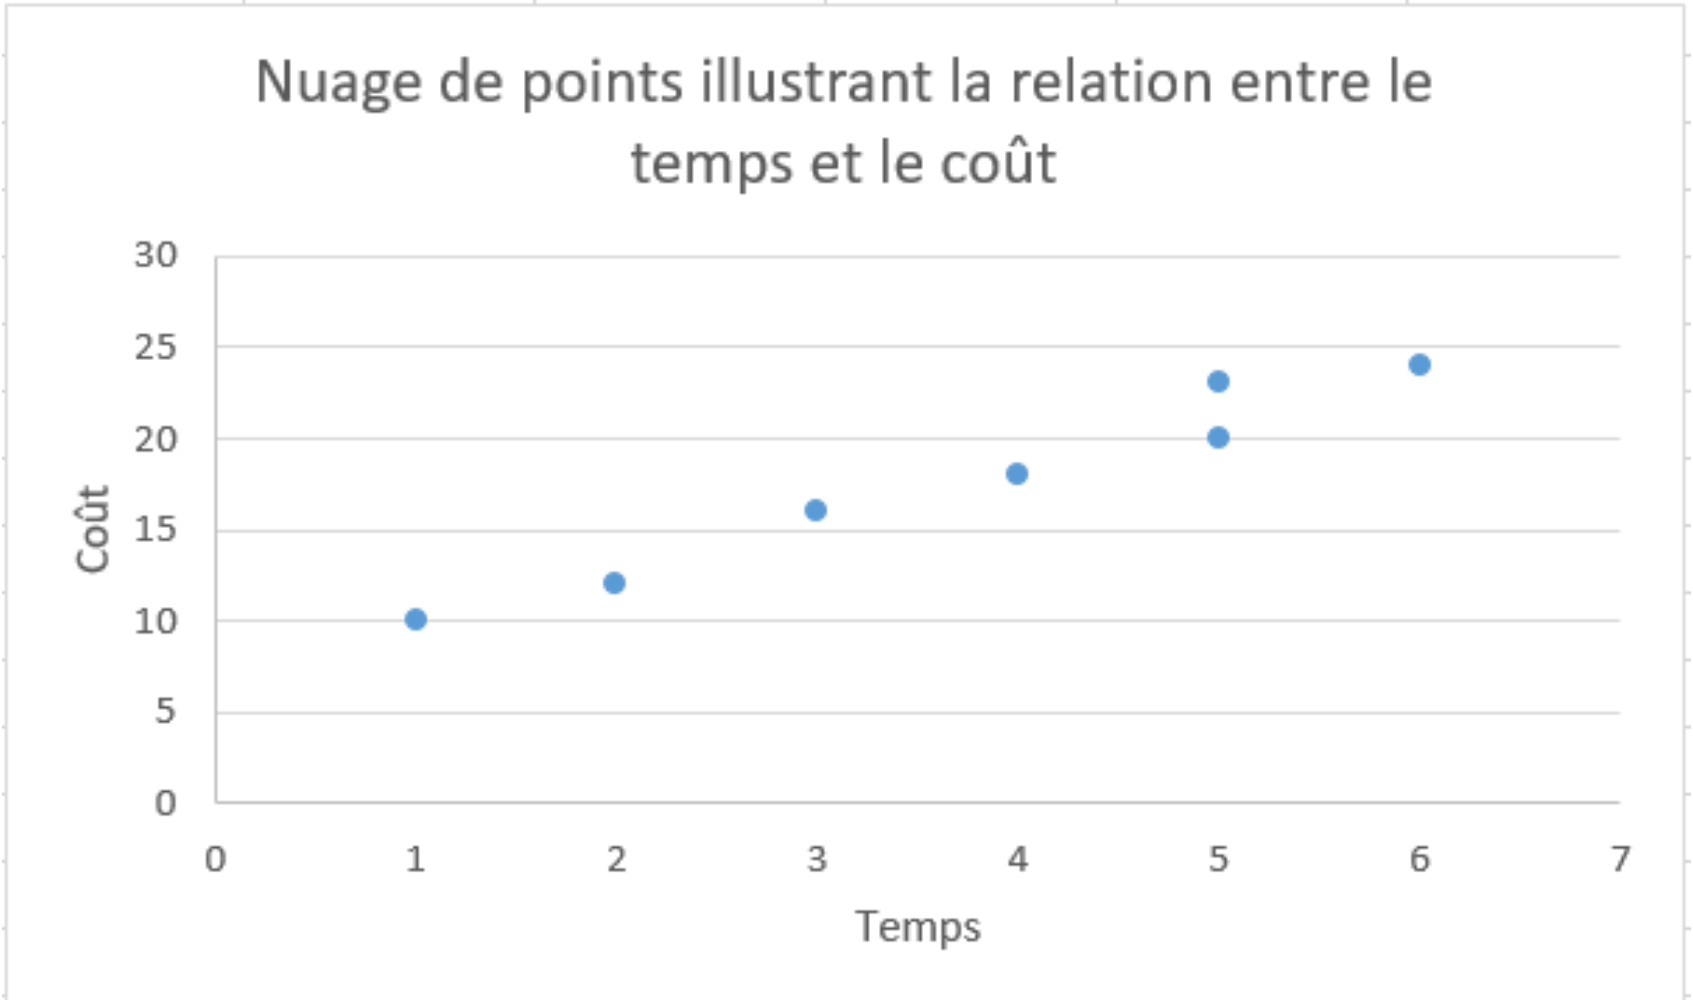
Cas de deux variables quantitatives

Dans le premier cas, on choisira la même échelle sur les deux axes ; dans le second cas, il est recommandé soit de représenter les variables centrées et réduites sur des axes orthonormés, soit de choisir des échelles telles que ce soit sensiblement ces variables là que l'on représente (c'est en général cette seconde solution qu'utilisent, de façon automatique, les logiciels statistiques).

Exemple :
Une usine de production à PIA produit des pièces de moto de marque MAUTO. Pour chaque pièce, on dispose du coût de sa production (FCFA) et du temps nécessaire pour sa réalisation (heures). Le tableau ci-après donne cette répartition.

Temps (heures)	1	3	5	2	4	5	6
Coût (FCFA)	10	16	23	12	18	20	24

Cas de deux variables quantitatives



Cas de deux variables quantitatives

L'indice de liaison :

Le **coefficient de corrélation linéaire** est un indice rendant compte numériquement de la manière dont les deux variables considérées varient simultanément. Il est défini à partir de la covariance qui généralise à deux variables la notion de variance :

$$Cov\,(X, Y) = \sigma_{xy} = \frac{1}{n}\sum_{i=1}^{\tau}(x_i - \overline{x})\,(y_i - \overline{y}) \tag{3}$$

$$= \frac{1}{n}\sum_{i=1}^{\tau} x_i y_i - \overline{x} * \overline{y} \tag{4}$$

Cas de deux variables quantitatives

Quelques propriétés de la covariance

- $Cov(X, X) = Var(X)$

La covariance dépend des unités de mesure dans lesquelles sont exprimées les variables considérées; en ce sens, ce n'est pas un indice de liaison *intrinsèque.* C'est la raison pour laquelle on définit le coefficient de corrélation linéaire appelé **coefficient de Pearson ou de Bravais-Pearson**. Ce coefficient de corrélation linéaire est le rapport entre la **covariance et le produits des écarts-types.**

Cas de deux variables quantitatives

Quelques propriétés de la covariance

- $Cov(X, X) = Var(X)$
- $Cov(X, Y) = Cov(Y, X)$

La covariance dépend des unités de mesure dans lesquelles sont exprimées les variables considérées; en ce sens, ce n'est pas un indice de liaison *intrinsèque.* C'est la raison pour laquelle on définit le coefficient de corrélation linéaire appelé **coefficient de Pearson ou de Bravais-Pearson**. Ce coefficient de corrélation linéaire est le rapport entre la **covariance et le produits des écarts-types.**

Cas de deux variables quantitatives

Quelques propriétés de la covariance

- $Cov(X, X) = Var(X)$
- $Cov(X, Y) = Cov(Y, X)$
- $Cov(aX, Y) = aCov(X, Y)$ où a est constante

La covariance dépend des unités de mesure dans lesquelles sont exprimées les variables considérées; en ce sens, ce n'est pas un indice de liaison *intrinsèque.* C'est la raison pour laquelle on définit le coefficient de corrélation linéaire appelé **coefficient de Pearson ou de Bravais-Pearson**. Ce coefficient de corrélation linéaire est le rapport entre la **covariance et le produits des écarts-types.**

Cas de deux variables quantitatives

Quelques propriétés de la covariance

- $Cov(X, X) = Var(X)$
- $Cov(X, Y) = Cov(Y, X)$
- $Cov(aX, Y) = aCov(X, Y)$ où a est constante
- $Cov(X + a, Y) = Cov(X, Y)$ où a est une constante

La covariance dépend des unités de mesure dans lesquelles sont exprimées les variables considérées; en ce sens, ce n'est pas un indice de liaison *intrinsèque.* C'est la raison pour laquelle on définit le coefficient de corrélation linéaire appelé **coefficient de Pearson ou de Bravais-Pearson**. Ce coefficient de corrélation linéaire est le rapport entre la **covariance et le produits des écarts-types.**

Cas de deux variables quantitatives

Quelques propriétés de la covariance

- $Cov(X, X) = Var(X)$
- $Cov(X, Y) = Cov(Y, X)$
- $Cov(aX, Y) = aCov(X, Y)$ où a est constante
- $Cov(X + a, Y) = Cov(X, Y)$ où a est une constante
- $Cov(X + Y, Z) = Cov(X, Z) + Cov(Y, Z)$ où X, Y et Z sont trois variables

La covariance dépend des unités de mesure dans lesquelles sont exprimées les variables considérées; en ce sens, ce n'est pas un indice de liaison *intrinsèque.* C'est la raison pour laquelle on définit le coefficient de corrélation linéaire appelé **coefficient de Pearson ou de Bravais-Pearson**. Ce coefficient de corrélation linéaire est le rapport entre la **covariance et le produits des écarts-types.**

Cas de deux variables quantitatives

Quelques propriétés de la covariance

- $Cov(X, X) = Var(X)$
- $Cov(X, Y) = Cov(Y, X)$
- $Cov(aX, Y) = aCov(X, Y)$ où a est constante
- $Cov(X + a, Y) = Cov(X, Y)$ où a est une constante
- $Cov(X + Y, Z) = Cov(X, Z) + Cov(Y, Z)$ où X, Y et Z sont trois variables
- Si les variables X et Y sont indépendantes alors la $Cov(X, Y) = 0$

La covariance dépend des unités de mesure dans lesquelles sont exprimées les variables considérées; en ce sens, ce n'est pas un indice de liaison *intrinsèque.* C'est la raison pour laquelle on définit le coefficient de corrélation linéaire appelé **coefficient de Pearson ou de Bravais-Pearson**. Ce coefficient de corrélation linéaire est le rapport entre la **covariance et le produits des écarts-types.**

Cas de deux variables quantitatives

$$Corr\,(X,Y) = \frac{cov\,(X,Y)}{\sigma_X \sigma_Y} \tag{5}$$

Le coefficient de corrélation est égale à la covariance des variables centrées et réduites respectivement associées à X et Y :
$corr\,(X,Y) = cov\left(\frac{X-\overline{x}}{\sigma_x}, \frac{Y-\overline{y}}{\sigma_y}\right)$
Par conséquent, $corr\,(X,Y)$ est indépendant des unités de mesure de X et de Y. Le coefficient de corrélation est **symétrique** et prends ses valeurs entre -1 et 1.

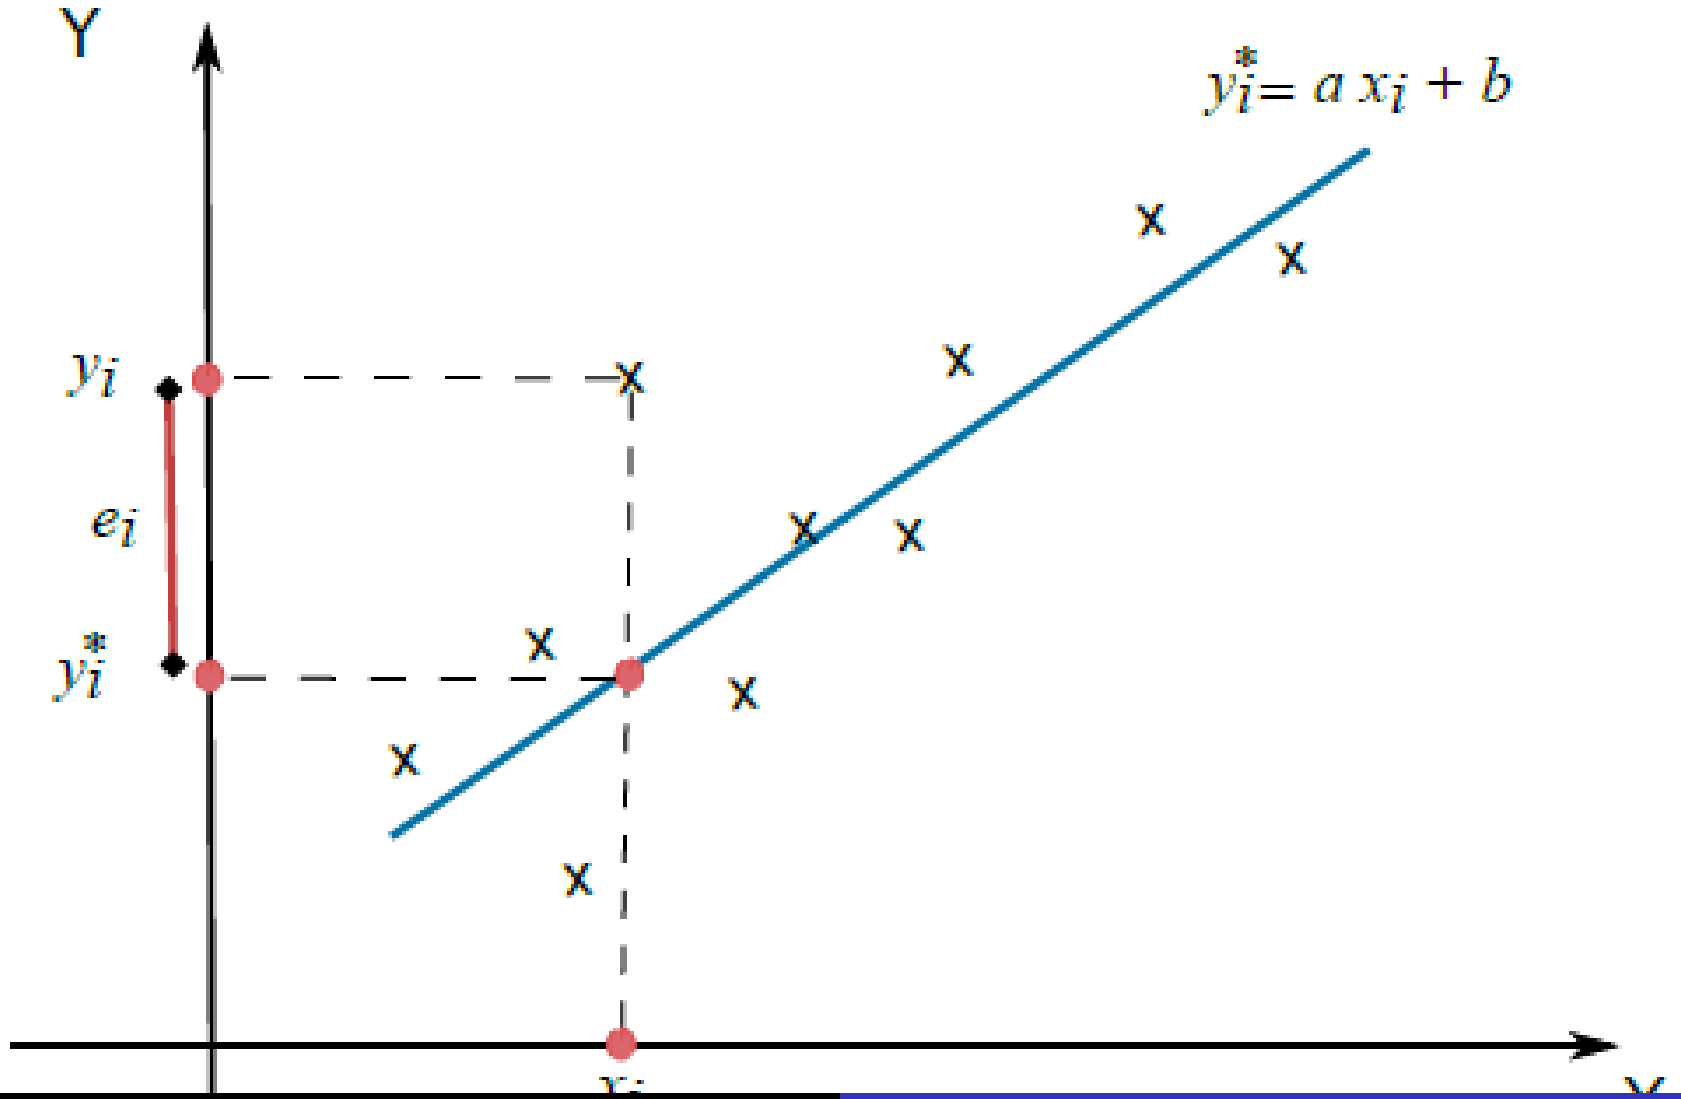
Cas de deux variables quantitatives

La droite de régression L'idée ici est de transformer le nuage de point en une droite. Cette droite doit être la plus proche possible de chacun des points. On cherche donc à minimiser les écarts entre les points et la droite. Pour y arriver, on utilise la méthode des **moindres carrées ordinaires.** Cette méthode vise à expliquer un nuage de points par une droite qui lie Y à X c'est à dire :

$$Y = aX + b, \tag{6}$$

telle que la distance entre le nuage de points et la droite soit minimale. Cette distance représente en effet l'erreur, c'est à dire la différence entre le point réellement observé et le point prédit par la droite. Notons que la méthode des moindres carrées ordinaires consiste à chercher la valeur des paramètres a et b qui minimise la somme des carrés des erreurs.

Figure 2 : La droite la plus proche des points du nuage



La méthode des moindres carrées ordinaires

On pose :

$$\sum_{i=1}^{r} e_i = U(a, b), \tag{7}$$

Rappelons que e_i est l'erreur commise sur chaque observation, c'est à dire,

$$\mid e_i \mid = \mid y_i - y_i^* = \mid y_i - ax_i - b \mid .$$

La méthode des moindres carrées consiste donc à minimiser la fonction U. Nous avons ainsi la fonction de minimisation suivante :

$$\frac{\partial U}{\partial a} = \frac{\partial U}{\partial b} = 0,$$

avec

La méthode des moindres carrées ordinaires

$$U(a,b) = \sum_{i=1}^{r} (y_i - ax_i - b)^2 .$$

Ainsi l'équation $\frac{\partial U}{\partial b} = 0$ donne :

$$\sum_{i=1}^{r} -2(y_i - ax_i - b) = 0$$

Il vient donc que

$$\left(\sum_{i=1}^{r} y_i - a \sum_{i=1}^{r} x_i - b \sum_{i=1}^{r} \right) = 0$$

On obtient donc :

$$\overline{y} - a\overline{x} - b = 0$$

c'est à dire :

$$\boxed{b = \overline{Y} - a\overline{X}} \tag{8}$$

De même $\frac{\partial U}{\partial a} = 0$ nous donne :

$$\boxed{a = \frac{Cov\,(X, Y)}{Var\,(X)}} \tag{9}$$

Application :
Trouver la droite de régression linéaire dans le cas de la production des pièces de moto de marque MAUTO.

Cas de deux variables qualitatives

On considère dans ce paragraphe deux variables qualitatives observées simultanément sur un échantillon de taille n. On suppose X la première variable et possédant r modalités notées $x_1, ..., x_l, ..., x_r$. Y sera la seconde variable avec t modalités notées $y_1, ..., y_h, ..., y_t$.

Tableau statistique

Ces données seront présentées dans un tableau à double entrée, appelé *table de contingence* dans lequel on dispose les modalités de la variable X en ligne et celle de la variable Y en colonne. Ce tableau est donc de dimension $r \times t$ et à pour élément générique le nombre n_{lh} d'observations conjointes des modalités x_l de X et y_h de Y. Les quantités n_{lh} sont appelés *effectifs conjoints*.
Une table de contingence se présente comme suit :

Cas de deux variables qualitatives

Table: Tableau de contingence

	y_1	...	y_h	...	y_c	sommes
x_1	n_{11}	...	n_{1h}	...	n_{1c}	n_{1+}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_l	n_{l1}	...	n_{lh}	...	n_{lc}	n_{l+}
$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\vdots$
x_r	n_{r1}	...	n_{rh}	...	n_{rc}	n_{r+}
sommes	n_{+1}	...	n_{+h}	...	n_{+c}	n

Cas de deux variables qualitatives

Les quantités $n_{l+}\,(l = 1, ..., r)$ et $n_{+h}\,(h = 1, ..., t)$ sont appelés *effectifs marginaux;* ils sont définis par $n_{l+} = \sum_{h=1}^{t} n_{lh}$ et $n_{+h} = \sum_{l=1}^{r} n_{lh}$ et ils vérifient $\sum_{l=1}^{t} n_{l+} = \sum_{h=1}^{r} n_{+h} = n$. De la même manière on peut définir les notions de fréquences conjointes ou de fréquences marginales.

Application

Lors d'une enquête alimentaire auprès de 50 personnes pour étudier la préférence alimentaire en fonction du genre, on a collecté les informations suivantes :

- 25 hommes préfèrent la viande
- 15 femmes préfèrent la viande
- 5 hommes sont végétariens
- 5 femmes sont végétariennes

Construisez le tableau de contingence pour représenter ces données.

Les lois marginales

Sur la marge du tableau de contingence, on peut extraire les données seulement par rapport à X et seulement par rapport à Y (voir le tableau de contingence établi précédemment.)

1. **Effectifs et fréquences marginales par rapport à Y :** nous avons, pour $j = 1, ..., c$

$$n_{+j} := \sum_{i=1}^{r} n_{ij},$$

et

$$f_{+j} := \frac{n_{+j}}{n} = \sum_{i=1}^{r} f_{ij}.$$

2. **Effectifs et fréquences marginales par rapport à X :** nous avons, pour $i = 1, ..., r$

Les lois marginales

$$n_{i+} := \sum_{i=1}^{c} n_{ij},$$

et

$$f_{i+} := \frac{n_{i+}}{n} = \sum_{i=1}^{c} f_{ij}.$$

Remarque :

$$\sum_{i=1}^{r} n_{ij} = \sum_{i=1}^{c} n_{ij} = n \quad et \quad \sum_{i=1}^{r} f_{ij} = \sum_{i=1}^{c} f_{ij} = 1$$

Les lois marginales

Exercice d'application

Nous considérons 10 salariés qui sont observés à l'aide de deux variables "âge" et "salaire". Les informations brutes sont données dans le tableau suivant :

salaire	6000	7400	7500	8200	8207	8900	9100	9900	9950	10750
âge	15	26	20	43	47	37	52	34	50	44

1. Déterminer le tableau de contingence (X : âge, Y : salaire). Pour l'âge et le salaire, former respectivement des classes de pas de 10 ans et de 1000 FCFA.
2. Calculer f_{21}, f_{12}, f_{45} et f_{33}
3. Déterminer les effectifs marginaux de X et de Y. Tracer le nuages de points.
4. Déterminer le tableau statistique des deux séries marginales X et Y .

Les lois marginales

Descriptions numériques

Caractéristiques des séries marginales

Dans le cas d'une série statistique à deux dimensions X et Y, les moyennes sont données respectivement par :

$$\overline{x} = \frac{1}{n}\sum_{i=1}^{r} n_{i+}x_i = \sum_{i=1}^{r} f_{i+}x_i$$

et,

$$\overline{y} = \frac{1}{n}\sum_{j=1}^{t} n_{+j}y_j = \sum_{j=1}^{t} f_{+j}y_j$$

Remarque :

Dans le cas continue, x_i et y_j représentent respectivement le centre des classes de X et Y

Les lois marginales

Série conditionnelle par rapport à X

Elle est notée X/y_j ou X_j et on dit que c'est la série conditionnelle de X sachant que $Y = y_j$. Nous calculons dans ce cas, la fréquence conditionnelle $f_{i/j}$ (f_i sachant j) pour $i = 1, ..., r$, par

$$f_{i/j} := \frac{n_{ij}}{n_{+j}} = \frac{f_{ij}}{f_{+j}}$$

Nous avons aussi la moyenne conditionnelle $\overline{x}_j$, c'est à dire la moyenne des valeurs de X sous la condition y_j, elle est définie par :

$$\overline{x}_j := \sum_{i=1}^{r} f_{i/j} x_i = \frac{1}{n_{+j}} \sum_{i=1}^{r} n_{ij} x_i$$

$$Var\left(X_j\right) := \sum_{i=1}^{r} f_{i/j} \left(x_i - \overline{x}_j\right)^2 = \overline{x^2}_j - \left(\overline{x}_j\right)^2$$

Les lois marginales

Série conditionnelle par rapport à Y

Elle est notée Y/x_i ou Y_i et on dit que c'est la série conditionnelle de Y sachant que $X = x_i$. Nous calculons dans ce cas, la fréquence conditionnelle $f_{j/i}$ (f_j sachant i) pour $j = 1, ..., k$, par

$$f_{j/i} := \frac{n_{ij}}{n_{i+}} = \frac{f_{ij}}{f_{i+}}$$

Nous avons aussi la moyenne conditionnelle $\overline{y}_i$, c'est à dire la moyenne des valeurs de Y sous la condition x_i, elle est définie par :

$$\overline{y}_i := \sum_{j=1}^{t} f_{j/i} y_j = \frac{1}{n_{i+}} \sum_{j=1}^{t} n_{ij} y_j$$

$$Var\left(Y_i\right) := \sum_{j=1}^{t} f_{j/i} \left(y_j - \overline{y}_i\right)^2 = \overline{y^2}_i - \left(\overline{y}_i\right)^2$$

Lois marginales : notion de covariance

$$Cov\,(X,Y) = \overline{xy} - \overline{x}\;\overline{y} = \frac{1}{n}\sum_{i=1}^{r}\sum_{j=1}^{t} n_{ij}x_i y_j - \overline{x}\;\overline{y}$$

Nous avons aussi :

$$Cov\,(X,Y) = \frac{1}{n}\sum_{i=1}^{r}\sum_{j=1}^{t} n_{ij}\,(x_i - \overline{x})\,(y_j - \overline{y})\,.$$

Pour rappel :

$$\overline{xy} = \frac{1}{n}\sum_{i=1}^{n} x_i y_i$$

Lois marginales

On dit que deux variables X et Y sont indépendantes si et seulement si, pour tout i et j

$$f_{ij} = f_{i+} \times f_{+j}$$

Il suffit que cette égalité ne soit pas vérifiée dans une seule cellule pour que les deux variables X et Y ne soient pas indépendantes. De manière équivalente, pour tout i et j

$$n \times n_{ij} = n_{i+} \times n_{+j}$$

Cette définition signifie que les effectifs des modalités conjointes peuvent se calculer uniquement à partir des distributions marginales des distributions de X et Y; en d'autres termes, si X et Y sont indépendantes, les observations séparées de X et de Y donnent la même information qu'une observation conjointe.

Introduction

Dans ce chapitre, il s'agira d'explorer les outils essentiels qui nous permettent de prendre des décisions éclairées à partir des données.

Nous définirons les termes essentielles pour meilleure compréhension du cours,nous étudierons un cas pratique de prise de décision et enfin nous étudierons les différents types de test

Définitions

Test d'hypothèse ou test statistique : procédé permettant de décider si une hypothèse donnée H_0 peut être acceptée ou être rejetée, au vu des données disponibles.

L'hypothèse H_0 à tester, appelée "hypothèse nulle" correspond à une absence de différence ou d'effet.

Exemples :

- H_0 : deux populations d'étudiants (de même niveau) ayant suivi des méthodes pédagogiques différentes ont les mêmes notes moyennes aux examens
- H_0 : le temps moyen de bon fonctionnement de deux marques de disques durs est le même.
- H_0 : la proportion de fumeurs chez les étudiants est la même que dans la population générale.

Définitions :

L'hypothèse alternative : noté H_1 est l'hypothèse contraire que l'on souhaite prouver en rejetant l'hypothèse nulle. Elle traduit une différence ou un effet statistiquement significatifs.

Exemples :

- H_1 deux populations d'étudiants ayant suivi des méthodes pédagogiques différentes ont des notes moyennes significativement différentes aux examens ;
- H_1 le temps moyen de bon fonctionnement du disque dur de la marque B est significativement différent de celui de la marque A.
- H_1 le temps moyen de bon fonctionnement du disque dur de la marque B est significativement supérieur à celui de la marque A.

Définitions

Le seuil de signification du test : Le risque, consenti à l'avance et que nous notons α de rejeter à tort l'hypothèse nulle H_0 alors qu'elle est vraie, s'appelle le **seuil de signification ou niveau de risque** et s'énonce comme suit :

$$\alpha = P\left(rejeter H_0 \mid H_0 vraie\right)$$

La P-valeur ou la P-value : Il s'agit de la probabilité d'obtenir des résultats aussi extrêmes que ceux observés, supposant, supposant que l'hypothèse nulle est vraie.

L' Erreur de type I : Rejeter à tort l'hypothèse nulle (faux positif).

Erreur de type II : Accepter à tort l'hypothèse nulle (faux négatif).

Étude de cas

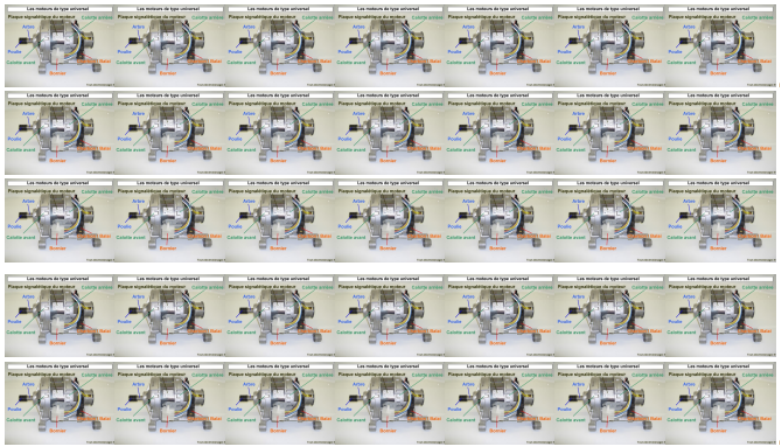
Durée de vie de moteurs électriques

Les moteurs des appareils électroménagers d'une marque M ont une durée de vie moyenne de $\mu_r = 3000$ heures avec un écart-type $\sigma_r = 150$ heures. A la suite d'une modification dans la fabrication des moteurs, le fabricant affirme que les nouveaux moteurs ont une durée de vie moyenne supérieure à celle des anciens.

- On teste un échantillon de $N = 50$ nouveaux moteurs. On note X_i les durées de vie observées.
- On calcule la durée de vie moyenne des nouveaux moteurs : $\overline{X} = \frac{1}{50}\sum_{i=1}^{50} X_i = 3040,3$ heures.
- Question : les nouveaux moteurs apportent-ils une amélioration statistiquement significative dans la duré de vie des appareils électroménagers ?

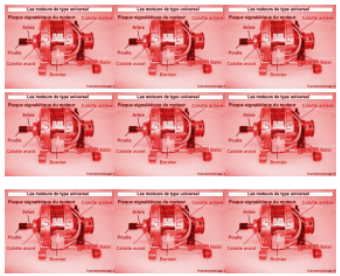
Étude de cas

Durée de vie de moteurs électriques



Référence : anciens moteurs

Durée de vie moyenne : μ_r=3000 h, σ_r = 150 h.



Echantillon : 50 nouveaux moteurs

Durée de vie moyenne empirique (observée) : $\bar{X}$ =3040,3 h.

Étude de cas

Durée de vie de moteurs électriques

- **Hypothèse** H_0 : le nouveau procédé ne change pas la durée de vie moyenne
- **Hypothèse** H_1 : le nouveau procédé augmente la durée de vie moyenne
- Comment décider ? $\Rightarrow$ on utilise l'écart entre $\overline{X}$ et la référence μ_r :
  - Ecart $\left(\overline{X} - \mu_r\right)$ faible $\rightsquigarrow H_0$
  - Ecart $\left(\overline{X} - \mu_r\right) > 0$ et grand $\rightsquigarrow H_1$
- Question : l'écart observé $\overline{X} - \mu_r = 40,3$ heures est-il "suffisamment grand" pour rejeter H_0 ?
- Intuitivement on comprend que la réponse dépendra de la valeur de l'écart mais aussi de la taille N de l'échantillon de test.

Étude de cas

Durée de vie de moteurs électriques

- **Hypothèse H_0 :** le nouveau procédé ne change pas la durée de vie moyenne
- L'écart observé $\overline{X} - \mu_r = 40,3$ heures est-il suffisamment grand pour rejeter H_0 ?
- Sous l'hypothèse H_0, la durée de vie d'un moteur testé est une variable aléatoire X de moyenne $\mu_r = 3000$ et d'écart type $\sigma_r = 150$ (NB. sa distribution n'est pas connue).
- D'après le Théorème Centrale Limite (TCL), sous H_0, la moyenne $\overline{X}$ de l'échantillon ($avec N = 50 > 30$) :

$$\overline{X} = \frac{1}{N}\sum_{i=1}^{N} X_i \sim \mathcal{N}\left(\mu_r, \frac{\sigma_r^2}{N}\right) \Rightarrow Z = \frac{\overline{X} - \mu_r}{\sigma_r/\sqrt{N}} \sim \mathcal{N}(0,1)$$

Étude de cas

Durée de vie de moteurs électriques

- Si H_0 est vraie : Ecart normalisé : $Z = \frac{\overline{X} - \mu_r}{\sigma_r / \sqrt{N}} \sim \mathcal{N}(0,1)$.
- Si H_0 est vraie :
  $p(Z > 1,64) = \int_{1,64}^{+\infty} f_Z(Z)\, dZ \simeq 0,05 = 5\%\,(\textit{faible})$
- Écart observé : $Z = z_0 = \frac{40,3}{150/\sqrt{50}} = 1,90 > 1,94$
- Décision : On rejette l'hypothèse H_0 avec 5% de chances de se tromper.

Caractéristiques générales d'un test d'hypothèse

- **Calcul de la statistique :** $Z = \frac{\overline{X} - \mu_r}{\sigma_r / \sqrt{N}} \sim \mathcal{N}(0,1$ Valeur observée : $Z = z_0$
- On se donne un **niveau de risque (ou seuil de signification)** α
- On détermine z_α tel que : $\alpha = p(Z > z_\alpha) = \int_{z_\alpha}^{+\infty} f_Z(z)\, dz$. z_α : **valeur critique (ou seuil de décision)**
  - Si $z_0 > z_\alpha$ on rejette l'hypothèse H_0 (on décide H_1)
  - Si $z_0 < z_\alpha$ on ne peut rejetter l'hypothèse H_0
- $\alpha = P(Z > \textit{seuil de decision}\, z_\alpha) = \int_{z_\alpha}^{+\infty} f_Z(z)\, dz$ (sous l'hypothèse H_0)
- α est la **probabilité de décider H_1 alors que H_0 est vraie.**. α est encore appelé **risque de première espèce.**
- Le choix de α est lié au risque que l'on accepte de prendre dans la décision. Ici :

Caractéristiques générales d'un test d'hypothèse

- Au niveau de risque
  $\alpha = 5\% : \ z_\alpha = 1.64, z_0 = 1.90 > 1.64 \Rightarrow$ *on rejette* H_0
- Au niveau de risque $\alpha = 1\% : z_\alpha = 2.33, z_0 = 1.90 < 2.33 \Rightarrow$ *on ne peut rejetter* H_0

Caractéristiques générales d'un test d'hypothèse

- $\alpha = P(Z > z_\alpha) = \int_{z_\alpha}^{+\infty} f_Z(z)\,dz$ où z_α est le seuil de décision.
- Pour une observation z_0 donnée, on appelle p-valeur, la plus petite valeur de α conduisant à un rejet de H_0. C'est la valeur de α obtenue en prenant comme seuil de décision : $z_\alpha = z_0$. Dans ce cas du test :

$$p - valeur = P(Z > z_0) = \int_{z_0}^{+\infty} f_Z(z)\,dz$$

- A.N. pour $z_0 = 1.90$ on a : p-valeur $= 0.0287$. Pour l'écart observé $z_0 = 1.90$ on rejettera H_0 pour tout choix de niveau de risque $\alpha \geq 2.87\%$
  - Si la p-valeur est inférieur à α on rejette H_0
  - Si la p-valeur est supérieur à α on ne peut rejeter H_0

Définition des p-valeurs pour les tests unilatéraux et bilatéraux

- Hypothèse H_0 : $\mu = \mu_r$
- **Test Unilatéral à droite :** $\mu > \mu_r$

$$p - valeur = \int_{z_0}^{+\infty} f_Z(z)\, dz$$

- **Test Unilatéral à gauche :** $\mu < \mu_r$

$$p - valeur = \int_{-\infty}^{z_0} f_Z(z)\, dz$$

- **Test bilatéral :** $\mu \neq \mu_r$

$$p - valeur = 2\int_{|z_0|}^{+\infty} f_Z(z)\, dz$$

Synthèse

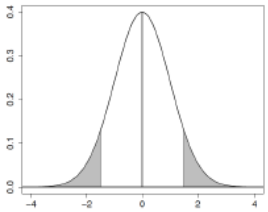
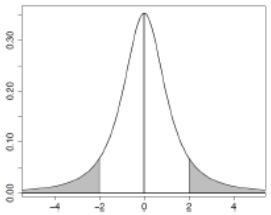
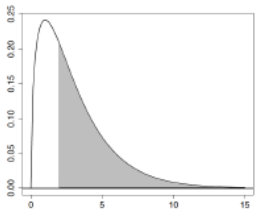
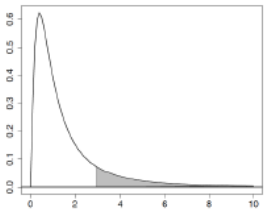
- **Construction d'un test statistique :**
  - **Hypothèse nulle** H_0 que l'on cherche à rejeter
  - **Hypothèse alternative** H_1 dont on souhaite démontrer la véracité
- On se donne un **niveau de risque** α
- On calcule une **statistique de test T**
- La valeur choisie pour α définit **la zone de rejet de** H_0 (ou région critique) $\mathfrak{R}_c$ dont la forme va dépendre du type de test (unilatéral ou bilatéral).

Les différents types de test

Les tests statistiques peuvent être regroupés en deux grands groupes à savoir :

- **Les tests paramétriques :** Ce sont des tests pour lesquels les distributions statistiques sont connus.
- **Les tests non paramétriques :** Ces tests ne nécessitent pas de connaissance des distributions. On effectue le test directement sur les N échantillons disponibles (avec N suffisamment grand).

Tests paramétriques classiques sur une seule population

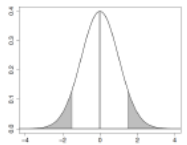
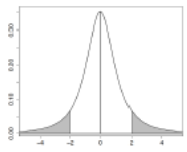
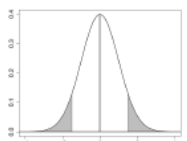
N. Meyer, LBIM, UdS

Il s'agit de déterminer si un paramètre d'une population est identique à une valeur de référence donné
Les paramètres testés sont : la moyenne, la variance, la proportion d'une modalité d'une variable qualitative dans la population.
Le test se base sur l'observation de N échantillons X_i tirés aléatoirement et indépendamment dans la population.

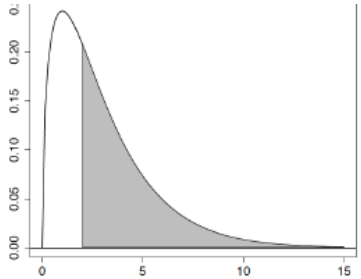
- Moyenne de référence : μ_r — Moyenne empirique des N échantillons : $\bar{X} = \frac{1}{N}\sum_{i=1}^{N} X_i$
- Variance de référence : σ_r^2 — Variance empirique : $S^2 = \frac{1}{N-1}\sum_{i=1}^{N}(X_i - \bar{X})^2$
- Proportion de référence : Π_r^2 — Proportion empirique : $\pi = \frac{\#\text{occurrences}}{N}$

Tests paramétriques classiques sur une seule population : Test sur la moyenne

Etablir si dans une population $\mathcal{P}$, la moyenne diffère d'une valeur de référence μ_r donnée.
Paramètre à tester : moyenne μ de la population $\mathcal{P}$.
Test réalisé à partir d'une moyenne empirique $\bar{X}$ calculée sur N échantillons, tirés de $\mathcal{P}$.

loi de la population		statistique	loi de la statistique	
normale	σ_r^2 connu	$Z = \frac{\bar{X}-\mu_r}{\sigma_r/\sqrt{N}}$	$\mathcal{N}(0,1)$ Test z	
	σ_r^2 inconnu	$T = \frac{\bar{X}-\mu_r}{S/\sqrt{N}}$	Student à $N-1$ ddl. Test t de Student	
quelconque ($N > 30$)	σ_r^2 connu	$Z = \frac{\bar{X}-\mu_r}{\sigma_r/\sqrt{N}}$	$\mathcal{N}(0,1)$ Test z	
	σ_r^2 inconnu	$Z = \frac{\bar{X}-\mu_r}{S/\sqrt{N}}$	$\mathcal{N}(0,1)$ Test z	

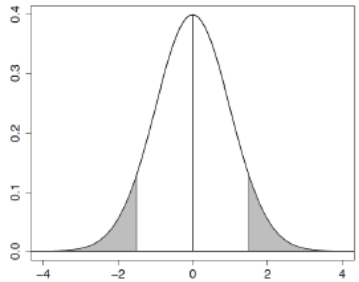
Tests paramétriques classiques sur une seule population : Test sur la variance



Etablir si dans une population $\mathcal{P}$, la variance diffère d'une valeur de référence σ_r^2 donnée.
Paramètre à tester : variance σ^2 de la population $\mathcal{P}$.
Test réalisé à partir d'une variance empirique S^2 calculée sur N échantillons, tirés de $\mathcal{P}$.

loi de la population		statistique	loi de la statistique
normale (ou quelc. $N > 30$)	μ_r connu	$\sum_{i=1}^{N} \frac{(X_i - \mu_r)^2}{\sigma_r^2}$	χ^2 à N ddl.
	μ_r inconnu	$(N-1)\frac{S^2}{\sigma_r^2}$	χ^2 à N-1 ddl.

Tests paramétriques classiques sur une seule population : Test sur la proportion

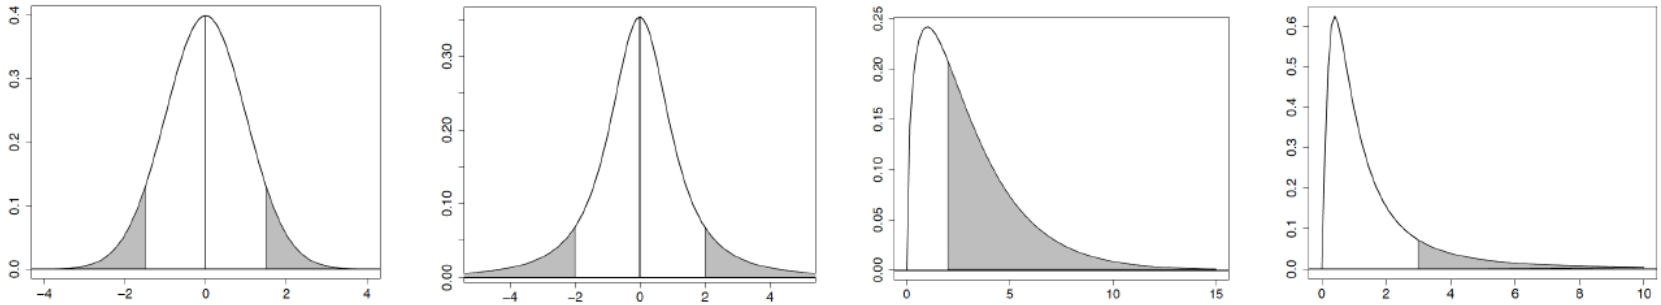


Proportion : part de la population qui possède telle modalité d'une variable qualitative (ex. : proportion de filles à la naissance).

Etablir si dans une population $\mathcal{P}$, une proportion diffère d'une valeur de référence Π_r.
Paramètre à tester : proportion Π dans la population $\mathcal{P}$.
Test réalisé à partir d'une proportion empirique π calculée sur N échantillons de $\mathcal{P}$.

loi de la population	statistique	loi de la statistique
quelconque $N > 30$, $N.\Pi_r > 5$ et $N.(1-\Pi_r) > 5$	$Z = \frac{\pi - \Pi_r}{\sqrt{\frac{\Pi_r.(1-\Pi_r)}{N}}}$	$\mathcal{N}(0,1)$

Tests paramétriques classiques : Cas de deux populations



Il s'agit de déterminer si deux populations distinctes $\mathcal{P}_1$ et $\mathcal{P}_2$ ont des paramètres identiques (moyennes, variances, proportions).

On dispose de N_1 échantillons $\{X_{i,1}\}$ tirés de la population $\mathcal{P}_1$, de N_2 échantillons $\{X_{i,2}\}$ tirés de la population $\mathcal{P}_2$.

- Moyennes empiriques : $\bar{X_1} = \frac{1}{N_1} \sum_{i=1}^{N_1} X_{i,1}, \quad \bar{X_2} = \ldots$
- Variances empiriques : $S_1^2 = \frac{1}{N_1 - 1} \sum_{i=1}^{N_1} (X_{i,1} - \bar{X_1})^2, \quad S_2^2 = \ldots$
- Proportions empiriques : $\pi_1 = \frac{\#\text{occurrences}}{N_1}, \quad \pi_2 = \ldots$

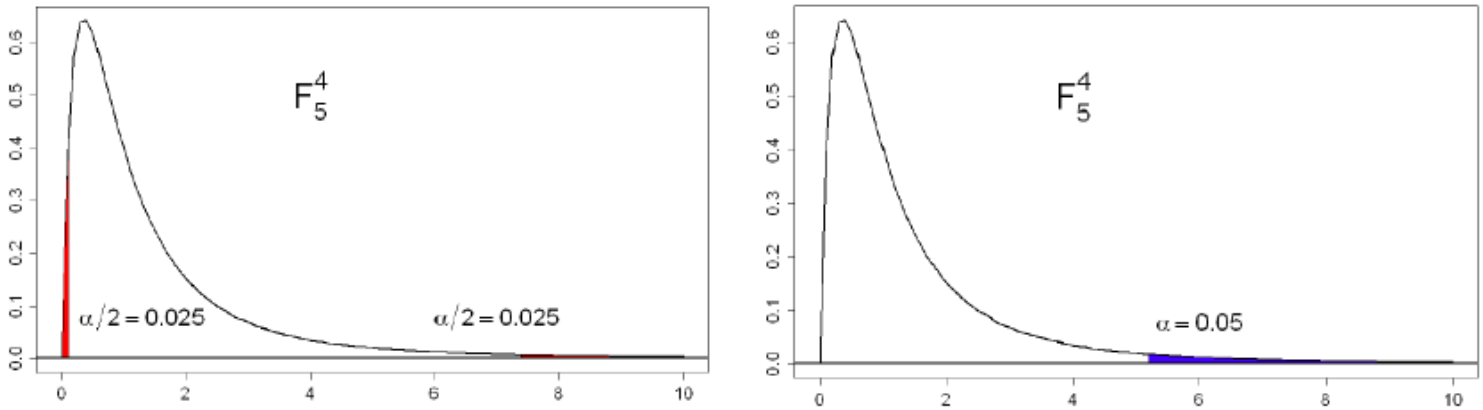


Tests paramétriques classiques : Cas de deux populations; Test sur les moyennes

Etablir si les moyennes de deux populations $\mathcal{P}_1$ et $\mathcal{P}_2$, diffèrent significativement.
Paramètre à tester : moyennes μ_1 et μ_2 des populations $\mathcal{P}_1$ et $\mathcal{P}_2$.
Test réalisé à partir des moyennes empiriques $\bar{X}_1$ et $\bar{X}_2$.

loi de la population		statistique	loi de la stat.
normale ou quelc. (N_1 et $N_2 > 30$)	σ_1^2, σ_2^2 connues	$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{\sigma_1^2}{N_1} + \frac{\sigma_2^2}{N_2}}}$	$\mathcal{N}(0,1)$ Test z
normale (N_1 et $N_2 > 30$)	σ_1^2, σ_2^2 inconnues	$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{N_1} + \frac{S_2^2}{N_2}}}$	Student à $(N_1 + N_2 - 2)$ ddl. Test t de Student
normale ($N_1 \leq 30$ ou $N_2 \leq 30$) (petits effectifs)	$\sigma_1^2 = \sigma_2^2$ inconnues variances égales ! (homoscédasticité)	$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{S^2\left(\frac{1}{N_1} + \frac{1}{N_2}\right)}}$ avec : $S^2 = \frac{(N_1-1)S_1^2 + (N_2-1)S_2^2}{N_1+N_2-2}$	Student à $(N_1 + N_2 - 2)$ ddl. Test t de Student
normale ($N_1 \leq 30$ ou $N_2 \leq 30$) (petits effectifs)	$\sigma_1^2 \neq \sigma_2^2$ inconnues (hétéroscédasticité)	$\frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{S_1^2}{N_1} + \frac{S_2^2}{N_2}}}$	*(non traité)* $\simeq$ Student à ν ddl. Test t de « Welch-Aspin »

Tests paramétriques classiques : Cas de deux populations; Test sur les variances



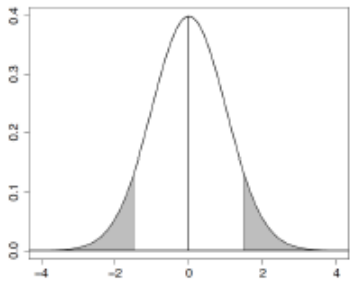
loi de Fisher $\alpha = 0,05$: test bilatéral - test unilatéral (N. Meyer, LBIM, UdS)

Etablir si les variances de deux populations $\mathcal{P}_1$ et $\mathcal{P}_2$, diffèrent significativement.
Paramètre à tester : variances σ_1^2 et σ_2^2 des populations $\mathcal{P}_1$ et $\mathcal{P}_2$.
Test réalisé à partir des variances empiriques S_1^2 et S_2^2 (les populations sont renumérotées pou que $S_1^2 > S_2^2$). Seuils pour le test bilatéral : $F_{\frac{\alpha}{2}\,\boldsymbol{inf}} = 1/F_{\frac{\alpha}{2}\,\boldsymbol{sup}}$.

Utilisation : en particulier tester l'*homoscédasticité* ($\sigma_1^2 = \sigma_2^2$) dans le test sur les moyennes.

loi de la population	statistique	loi de la stat.
normale	$F = \frac{S_1^2}{S_2^2}$	Fisher à $(N_1 - 1)$ et $(N_2 - 1)$ ddl.

Tests paramétriques classiques : Cas de deux populations; Test sur les proportions



Etablir si les proportions d'une modalité d'une variable qualitative diffèrent significativement dans deux populations $\mathcal{P}_1$ et $\mathcal{P}_2$.
Paramètre à tester : proportions Π_1 et Π_2 dans les populations $\mathcal{P}_1$ et $\mathcal{P}_2$.
Test réalisé à partir des proportions empiriques π_1 et π_2.

loi de la population	statistique	loi de la stat.
quelconque (N_1 *et* $N_2 > 30$) et : ($N_1.\pi_1 > 5$, $N_1.(1-\pi_1) > 5$, $N_2.\pi_2 > 5$, $N_2.(1-\pi_2) > 5$)	$\frac{\pi_1 - \pi_2}{\sqrt{\pi_c.(1-\pi_c)(\frac{1}{N_1}+\frac{1}{N_2})}}$ avec : $\pi_c = \frac{N_1\pi_1 + N_2\pi_2}{N_1+N_2}$	$\mathcal{N}(0,1)$

Extension : test du χ^2 de Pearson, permet de tester l'égalité des proportions de M modalités dans P populations

Formules importantes

Première étape : Déterminer la classe du quartile
Première étape : identifier la classe contenant le quartile
La classe du quartile est celle où la fréquence cumulée devient égale ou dépasse la position du quartile. Il faut repérer la classe dans laquelle se trouve cette position.
Troisième étape : Formule d'interpolation linéaire

$$Q_k = L_i + \left(\frac{P_k - Fi - 1}{f_i} \right) \times h$$

- L_i est la borne inférieur de la classe contenant le quartile
- P_k est la position du quartile dans la série
- F_{i-1} est la fréquence cumulée juste avant la classe du quartile
- f_i est l'effectif de la classe du quartile
- h est l'amplitude de la classe du quartile